방학 2주차

PERCEPTRON/MLP


NEKA

(1) Perceptron이란




우리의 뇌는 neuron이라는 신경세포가 촘촘하게 연결되어 있음.

- 뉴런: 전기 신호를 보내고 받는 신경 세포
- 신경계의 가장 기본이 되는 단위




(1) Perceptron이란

Neuron




Perceptron




(1) Perceptron이란

Perceptron은 이항분류를 하기 위한 알고리즘

- 뉴런의 돌기들은 각각 input과 output이 됨.
- 뉴런에서 각 synapse의 강도는 가중치가 됨.



(1) Perceptron이란



(A)
$$Y=WX+B$$

(B) sigmoid

(1) Perceptron이란

(A)
$$Y=WX+B$$

$$y=ax+b$$

X	У	
20	30	
30	40	
19	??	

$$\rightarrow$$
 y=a1x1+a2x2+a3x3+b

x 1	x2	х3	у
20	30	23	56
30	40	23	50
19	25	54	??

$$\longrightarrow$$

- (1) Perceptron이란
 - (B) sigmoid

- (1) Perceptron이란
 - (B) Activation Function

앞선 입력을 합쳐서 출력할 수 있도록 변환함

Sigmoid의 특성

- Logistic 이라고도 함.
- S자형 구조임.
- x값에 따라 0~1의 값을 가짐.


종류


1. Sigmoid

$$sigmoid(x) = rac{1}{1 + e^{-x}}$$

Sigmoid의 한계점

• Vanishing Gradient 문제가 있음





- (1) Perceptron이란
 - (B) Activation Function

앞선 입력을 합쳐서 출력할 수 있도록 변환함

tanh의 특성

- '쌍곡선'과 관련 있는 개념임.
- S자형 구조임.
- 함수의 중심점이 0임.


종류


2. Tanh

$$tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

tanh의 한계점

• Vanishing Gradient 문제가 여전히 있음





- (1) Perceptron이란
 - (B) Activation Function

앞선 입력을 합쳐서 출력할 수 있도록 변환함

tanh의 특성

- '쌍곡선'과 관련 있는 개념임.
- S자형 구조임.
- 함수의 중심점이 0임.


종류


2. Tanh

$$tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

tanh의 한계점

• Vanishing Gradient 문제가 여전히 있음





- (1) Perceptron이란
 - (B) Activation Function

앞선 입력을 합쳐서 출력할 수 있도록 변환함

ReLU의 특성

- Vanishing Gradient를 해결함
- 0보다 작으면 값이 0임.
- 학습이 비교적 빠르고, 연산 비용이 적음


종류

3. ReLU (Rectified Linear Unit)

$$f(x) = max(0, x)$$

ReLU의 한계점

• Dying ReLU 문제가 있음



- (1) Perceptron이란
 - (B) Activation Function

앞선 입력을 합쳐서 출력할 수 있도록 변환함

Leaky ReLU의 특성

- Dying ReLU 문제를 해결함
- 0보다 작으면 값이 0임.
- 학습이 비교적 빠르고, 연산 비용이 적음


종류

4. Leaky ReLU

$$f(x) = max(0.01x, x)$$


Leaky ReLU의 한계점


• 음수 파트가 중요할 때 쓰기 어려움



MLP

(1) MLP란?






단층

다층


MLP


(1) MLP란?



MLP

(1) MLP란?






ANN DNN

Cost Function

(1) Cost Function이란?

'실제 답'과 '학습의 결과'의 차이를 수치화한 것



Cost Function

(1) Cost Function이란?

종류

1. MSE: Mean Squared Error

$$MSE = rac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

2. RMSE: Root Mean Squared Error

$$RMSE = \sqrt{\sum_{i=1}^n rac{(\hat{y}_i - y_i)^2}{n}}$$

3. RAE: Mean Absolute Error


$$MAE = rac{1}{n} \sum_{i=1}^n |x_i - x|$$

4. R²:
$$R^2 = \frac{SSR}{SST} = \frac{\sum (\hat{y}_i - \bar{y})^2}{\sum (y_i - \bar{y})^2}$$

4. CrossEntropy: $H(p,q) = -\int_x p(x) \log q(x) dx$


(1) Forward Propagation

$$f = (x_1 w_1 + x_2 w_2) w_3$$




(1) Forward Propagation


$$f = (x_1 w_1 + x_2 w_2) w_3$$



(2) Back Propagation



(2) Back Propagation



(2) Back Propagation

$$\frac{\partial f}{\partial w_1} = \frac{\partial f}{\partial A} \frac{\partial A}{\partial w_1} \longrightarrow \frac{\partial C}{\partial w_1} = \frac{\partial C}{\partial f} \frac{\partial f}{\partial A} \frac{\partial A}{\partial w_1}$$

Gradient Descent

(1) Gradient Descent란?

비용함수를 최소화하는 값을 찾기

$$w := w - \alpha \frac{\partial c}{\partial w}$$

Optimization

(1) Optimization이란?

비용함수를 최소화하는 값을 찾기

Gradient Descent

$$w \coloneqq w - \alpha \frac{\partial c}{\partial w} + \mathbf{a}?$$

NEKA


Optimization

(2) Optimization의 종류

(1) SGD

GD vs SGD

- GD는 전부다 학습이 진행된 다음에 업데이트를 함 vs
- SGD는 학습 중간마다 업데이트를 함




Algorithm 2 Stochastic Gradient Descent at Iteration k

Require: Learning rate ϵ_k Require: Initial Parameter θ

- 1: while stopping criteria not met do
- Sample example $(\mathbf{x}^{(i)}, \mathbf{y}^{(i)})$ from training set
- : Compute gradient estimate:
- 4: $\hat{\mathbf{g}} \leftarrow +\nabla_{\theta} L(f(\mathbf{x}^{(i)}; \theta), \mathbf{y}^{(i)})$
- 5: Apply Update: $\theta \leftarrow \theta \epsilon \hat{\mathbf{g}}$
- 6: end while


Optimization

(2) Optimization의 종류



Optimization


(2) Optimization의 종류



(1) Overfitting Underfitting

Overfitting: Training loss는 낮은데 Test loss가 높을 때


Underfitting: Training과 Test 모두 loss가 높을 때




(2) bias \text{\text{\$\Omega\$}} variance

bias: 예측값과 정답의 차이에 대한 정도

variance: 예측값 사이의 차이에 대한 정도





(3) Overfitting을 해결하는 법

간단한 방법

- 1.데이터셋의 숫자를 늘리기
- 2.모델의 복잡도를 줄이기

복잡한 방법


- 1. Regularization
- 2. Dropout
- 3. Back-Normalization

(4) Regularization

가중치가 너무 커지는 것을 막음

L1 Regularization (Lasso 정규화)

$$C = C_0 + \frac{\lambda}{n} \sum_{w} |w|$$




L2 Regularization (Ridge 정규화)

$$C = C_0 + \frac{\lambda}{2n} \sum_{w} w^2$$


(5) Dropout

레이어에서 특정 확률로 뉴런을 제거함



https://heytech.tistory.com/

- (6) Batch Normalization
 - Internal Covariance Shift : 레이어를 지나갈 때마다 입력값의 분포가 달라짐



- (6) Batch Normalization
 - 정규화 과정을 통해 평균과 분산을 일정하게 조정함

$$\hat{x}^k = \frac{x^k - E[x^k]}{\sqrt{Var[x^k]}}$$

$$y^k = \gamma^k \hat{x} + \beta^k$$

NEKA

THANK YOU