

방학 3주차

CNN&LSTM&RNN

NEKA

CNN

Convolution이란?

- 우리말로 '합성곱'이라고 함.
- 함수 A, B가 있을 때 A를 반전한 것=A(t-τ)과 B의 곱을 적분한 것


$$f(t) = f_1(t) * f_2(t) = \int_{-\infty}^{\infty} f_1(\tau) f_2(t - \tau) d\tau, \quad -\infty < t < \infty$$

(전기신호에서의 개념)

CNN

Convolution 계산하기

$$(f * g)[n] = \sum_{m=-\infty}^{\infty} f[m] g[n - m]$$



CNN

1D Convolution 계산하기

$f : [3, 1, 2]$
 $g = [3, 2, 1]$
 $n=0$

$$(f * g)[n] = \sum_{m=-\infty}^{\infty} f[m] g[n - m]$$

m	-2	-1	0	1	2	3	4	5
f[m]	0	0	3	1	2	0	0	0
g[0-m]	1	2	3	0	0	0	0	0

$$(0 * 1) + (0 * 2) + (3 * 3) = 9$$

CNN

1D Convolution 계산하기

$$\begin{aligned} f &: [3, 1, 2] \\ g &= [3, 2, 1] \\ n &= 1 \end{aligned}$$

$$(f * g)[n] = \sum_{m=-\infty}^{\infty} f[m] g[n - m]$$

m	-2	-1	0	1	2	3	4	5
f[m]	0	0	3	1	2	0	0	0
g[1-m]	0	1	2	3	0	0	0	0

$$(0 * 1) + (3 * 2) + (1 * 3) = 9$$

CNN

1D Convolution 계산하기

$f : [3, 1, 2]$
 $g = [3, 2, 1]$
 $n=2$

$$(f * g)[n] = \sum_{m=-\infty}^{\infty} f[m] g[n - m]$$

m	-2	-1	0	1	2	3	4	5
f[m]	0	0	3	1	2	0	0	0
g[2-m]	0	0	1	2	3	0	0	0

$$(3 * 1) + (1 * 2) + (2 * 3) = 11$$

CNN

1D Convolution 계산하기

$$\begin{aligned} f &: [3, 1, 2] \\ g &= [3, 2, 1] \\ n &= 3 \end{aligned}$$

$$(f * g)[n] = \sum_{m=-\infty}^{\infty} f[m] g[n - m]$$

m	-2	-1	0	1	2	3	4	5
f[m]	0	0	3	1	2	0	0	0
g[3-m]	0	0	0	1	2	3	0	0

$$(1 * 1) + (2 * 2) + (0 * 3) = 5$$

CNN

1D Convolution 계산하기

$f : [3, 1, 2]$
 $g = [3, 2, 1]$
 $n=4$

$$(f * g)[n] = \sum_{m=-\infty}^{\infty} f[m] g[n - m]$$

m	-2	-1	0	1	2	3	4	5
f[m]	0	0	3	1	2	0	0	0
g[4-m]	0	0	0	0	1	2	3	0

$$(2 * 1) + (0 * 2) + (0 * 3) = 2$$

CNN

1D Convolution 계산하기

$$\begin{aligned} f &: [3, 1, 2] \\ g &= [3, 2, 1] \\ n &= 4 \end{aligned}$$

$$(f * g)[n] = \sum_{m=-\infty}^{\infty} f[m] g[n - m]$$

$$f * g [n] = [9, 9, 11, 5, 2]$$

CNN

2D Convolution 계산하기

- x, y 방향으로 convolution을 진행함.
- 2D의 의미 : input은 2차원이 아니어도 되지만, result는 2차원이어야 함

$$f[x,y] * g[x,y] = \sum_{n_1=-\infty}^{\infty} \sum_{n_2=-\infty}^{\infty} f[n_1,n_2] \cdot g[x-n_1,y-n_2]$$



CNN

2D Convolution 계산하기

1	2	3	4	5
2	3	4	5	6
3	4	5	6	7
1	3	5	7	9
2	4	6	8	1



1	2	3	4	5
2	3	4	5	6
3	4	5	6	7
1	3	5	7	9
2	4	6	8	1



1	2	3	4	5
2	3	4	5	6
3	4	5	6	7
1	3	5	7	9
2	4	6	8	1



1	2	3	4	5
2	3	4	5	6
3	4	5	6	7
1	3	5	7	9
2	4	6	8	1



.....


CNN

머신러닝에서 convolution의 의미


- input이미지에 특정한 필터를 적용하는 것



*



=



$$G_{\sigma} = \frac{1}{2\pi\sigma^2} e^{-\frac{(x^2+y^2)}{2\sigma^2}}$$


CNN

CNN이란?

- ConvNet이라고도 함.
- DNN의 일종으로, 시각 이미지를 분석할 때 보통 적용함.
- CNN은 MLP의 regularized 버전이라고도 할 수 있음

CNN

이미지 처리에서 ANN을 쓰기 어려운 이유




$A A A A = A ?$


CNN

Parameter sharing

- filter을 여기저기 돌아가며 쓰기 때문에 파라미터를 줄여줌



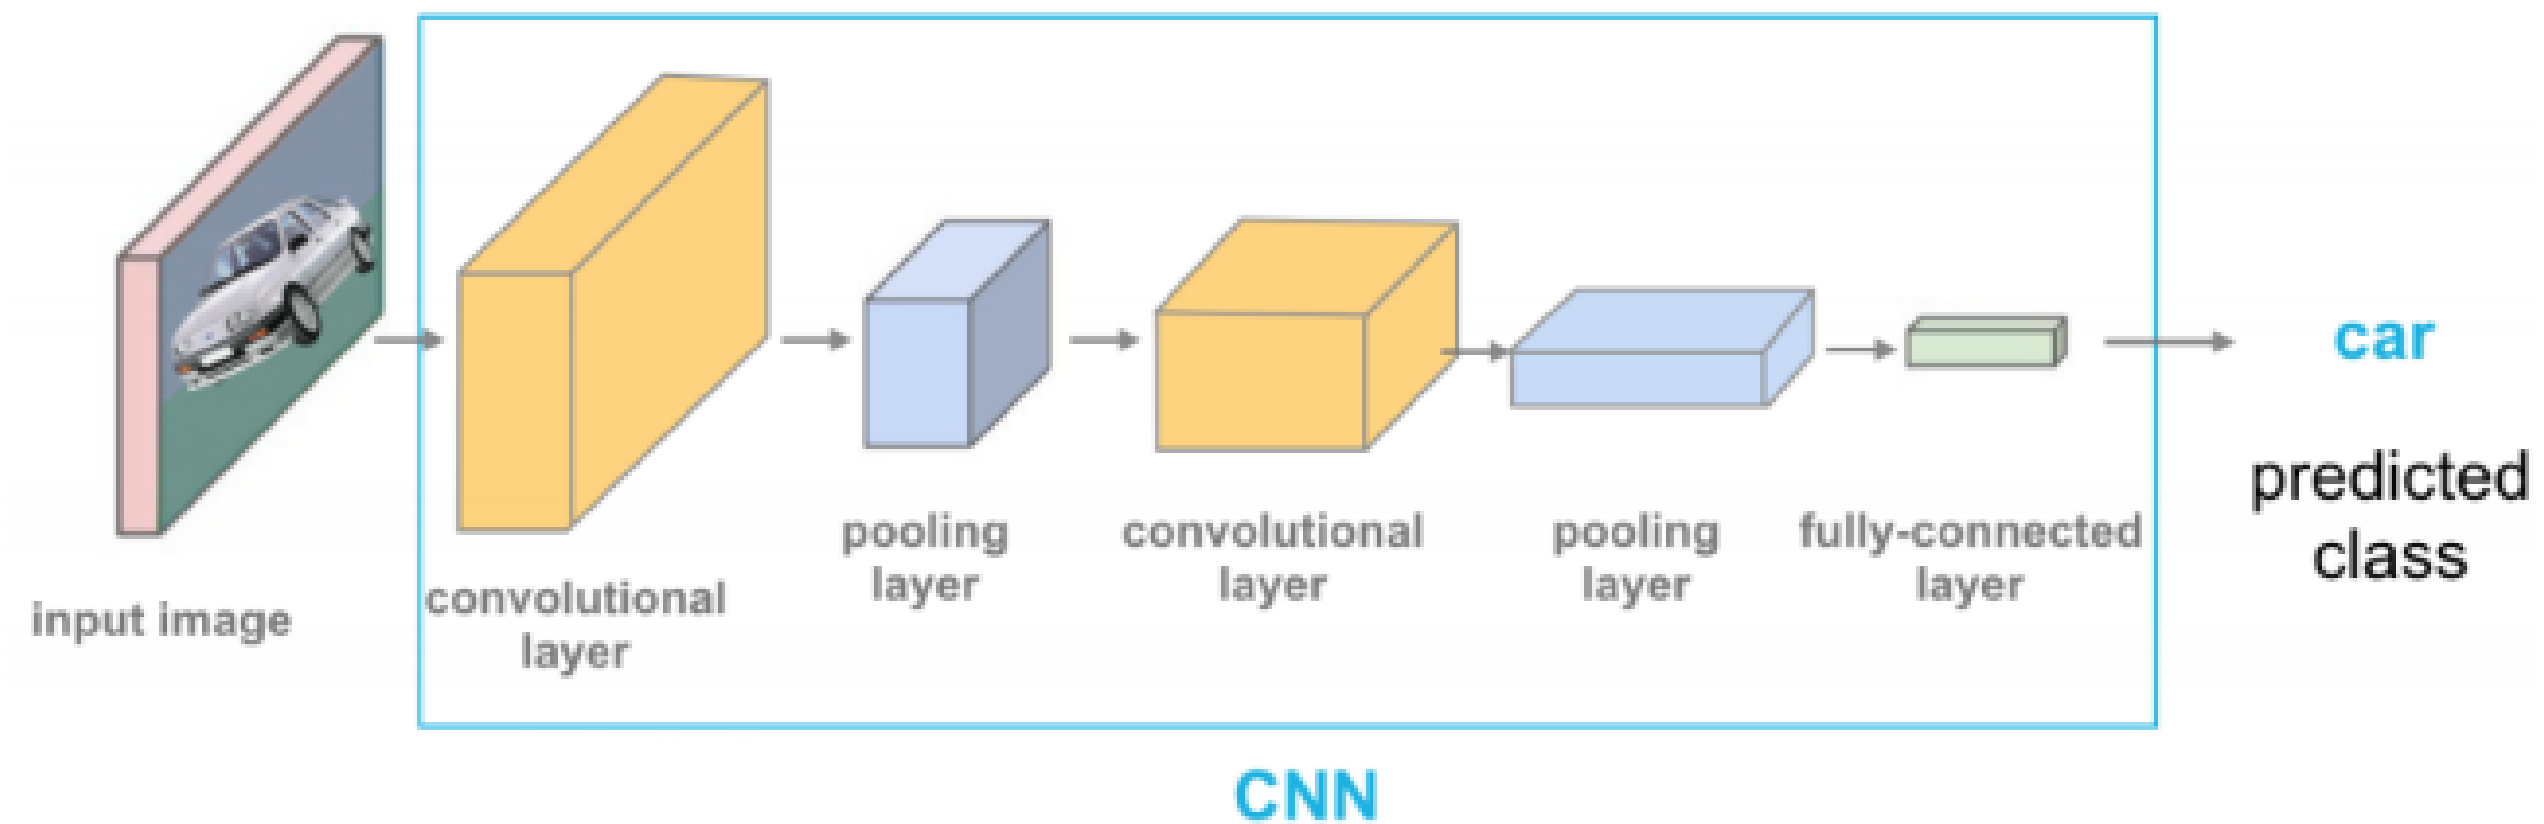
Feedforward neural network with three layers



Convolutional neural network with two layers




CNN

CNN 세부 구조



CNN

CNN 세부 구조 - Convolutional Layer



CNN

CNN 세부 구조 - Padding

- output size를 input size에 맞추기 위해 input 사이즈 외부에 0으로 구성된 열을 추가해줌
- padding의 크기는 $(\text{커널 길이} - 1) / 2$ (소수면 내림)로 함

3 ₀	3 ₁	2 ₂	1	0
0 ₂	0 ₂	1 ₀	3	1
3 ₀	1 ₁	2 ₂	2	3
2	0	0	2	2
2	0	0	0	1

12	12	17
10	17	19
9	6	14

Image

0	0	0	0	0	0	0
0	3 ₀	3 ₁	2 ₂	1	0	0
0	0 ₂	0 ₂	1 ₀	3	1	0
0	3 ₀	1 ₁	2 ₂	2	3	0
0	2	0	0	2	2	0
0	2	0	0	0	1	0
0	0	0	0	0	0	0

12	12	17
10	17	19
9	6	14

CNN


Receptive Field (수용 영역)

- 뉴런에서 Receptive Field는 한 뉴런을 흥분시킬 수 있는 자극의 영역을 말함
- 머신러닝에서는 filter의 크기를 말함
- Receptive Field를 키우는 방법
 - 커널의 크기를 키운다
 - Layer을 더 깊게 만든다.
 - Dilated Convolution
 - 이미지의 크기를 줄인다
 - Stride
 - Pooling

CNN

CNN 세부 구조 - Stride



- 옆으로 갈 때 지나가는 개수를 결정



CNN

CNN 세부 구조 - Pooling


- 작은 규모로 나눠서 크기를 줄임
- Pooling의 종류 :
 - Max-Pooling : 범위 내 가장 큰 값 뽑기
 - Average-Pooling : 범위 내 평균값 뽑기



CNN

Fully-connected Layer


- flatten, linear, classification layer라고 부르기도 함.
- 일반적으로 마지막 레이어 뒤에 붙여서 분류 작업을 할 때 씬.



CNN

1x1 convolution

- 크기가 1X1인 필터를 사용하는 레이어
- 장점
 - 채널수를 마음대로 결정할 수 있음
 - 연산량을 감소시킬 수 있음
 - 모델을 비선형적으로 만들어서 더 복잡하게 만들어줌



RNN


Recurrent란

- RNN에서 Recurrent는 repetitive의 의미를 가짐
 - Input 데이터는 sequential(순차적)
 - parameter는 순차적임


RNN

Sequential Data


- data point : 각 시가에 따른 vector x 의 sequence
- batch data : 서로 다른 길이를 가진 sequence
- label : scalar, vector, 혹은 sequence
- 서로 다른 종류의 sequence들도 label이 될 수 있음



DNA 염기 서열
(Sequential Data)



세계 기온 변화
(Temporal Sequence)



샘플링된 소리 신호
(Time Series)


순서가 의미가 있으며, 순서가 달라질 경우 의미가 손상되는 데이터를 **순차 데이터**라고 한다.

시간적 의미가 있는 경우 **Temporal Sequence**라고 하며, 일정한 시간차라면 **Time Series**라고 한다.

RNN


RNN이란

- 입력과 출력을 시퀀스 단위로 처리하는 모델




RNN


RNN 구조들




ONE TO ONE
(기본형)




ONE TO MANY



MANY TO ONE



MANY TO MANY
1




MANY TO MANY
2

RNN

seq2seq

- Many-to-One 와 One-to-Many를 합한 것
- 주로 번역기에서 사용함

인코더



디코더

RNN

RNN의 input과 output

- RNN의 INPUT은
 - sequence인 데이터
 - 이전의 hidden state
- RNN의 OUTPUT은
 - 현재의 hidden state
 - 처리된 결과물 (마지막)

RNN


hidden state와 Memory cell

- hidden state는 다음 cell로 보낼 값
ex)

$$h_t = f_w(h_{t-1}, x_t)$$

Some function with parameters W
 New state Old state Input vector at some time step

- Memory Cell은 RNN에서 하나의 Layer을 지칭하는 말




RNN

RNN의 Computational Graph

$$h_t = \psi(W h_{t-1} + U x_t) \quad \Psi(\text{psi}) : \tanh \text{ 등}$$

$$\hat{y}_t = \phi(V h_t) \quad \phi(\text{phi}) : \text{softmax 등}$$



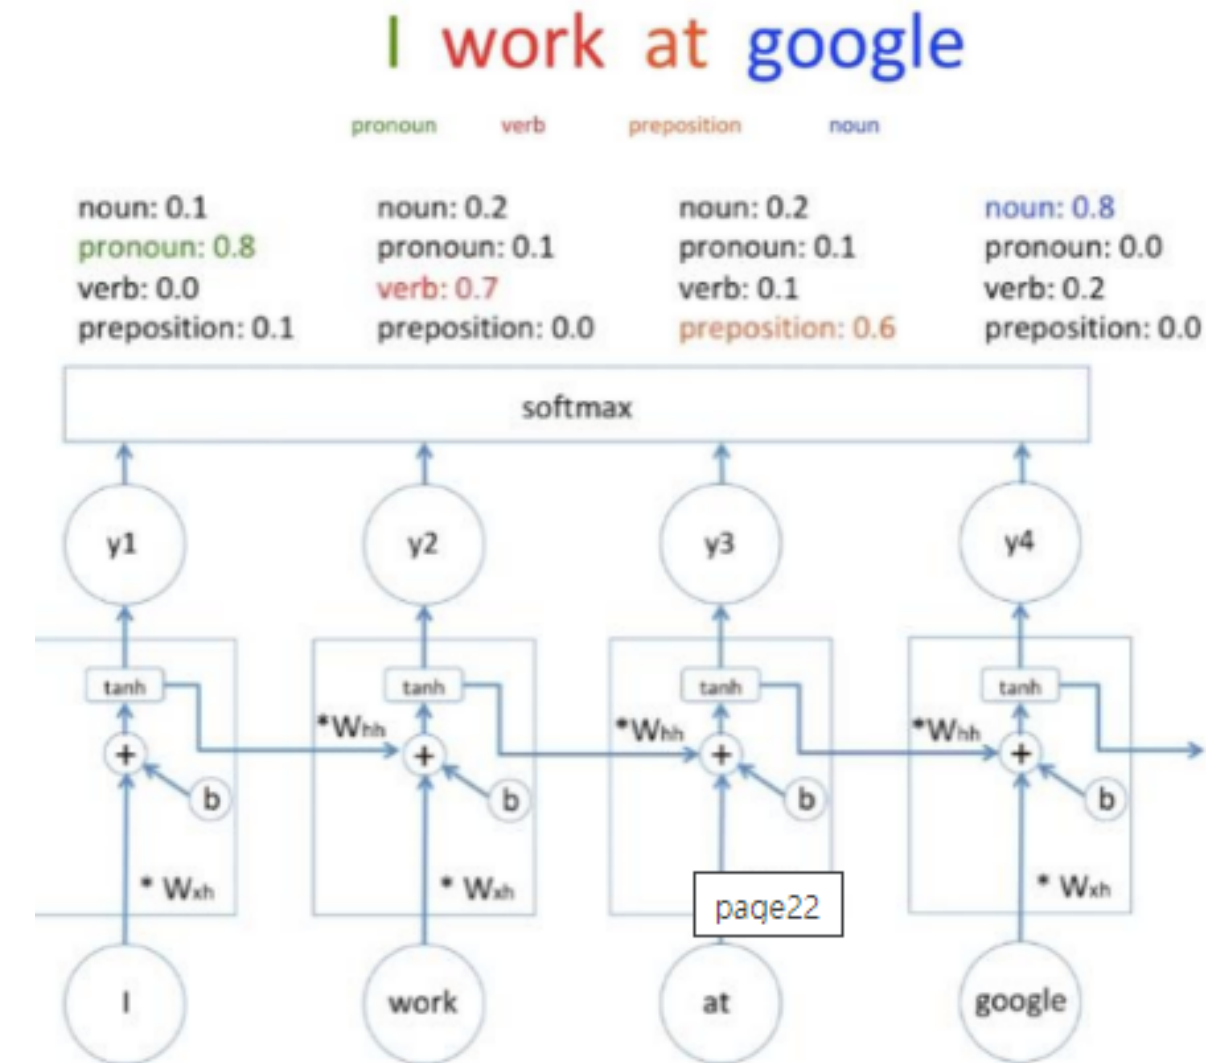
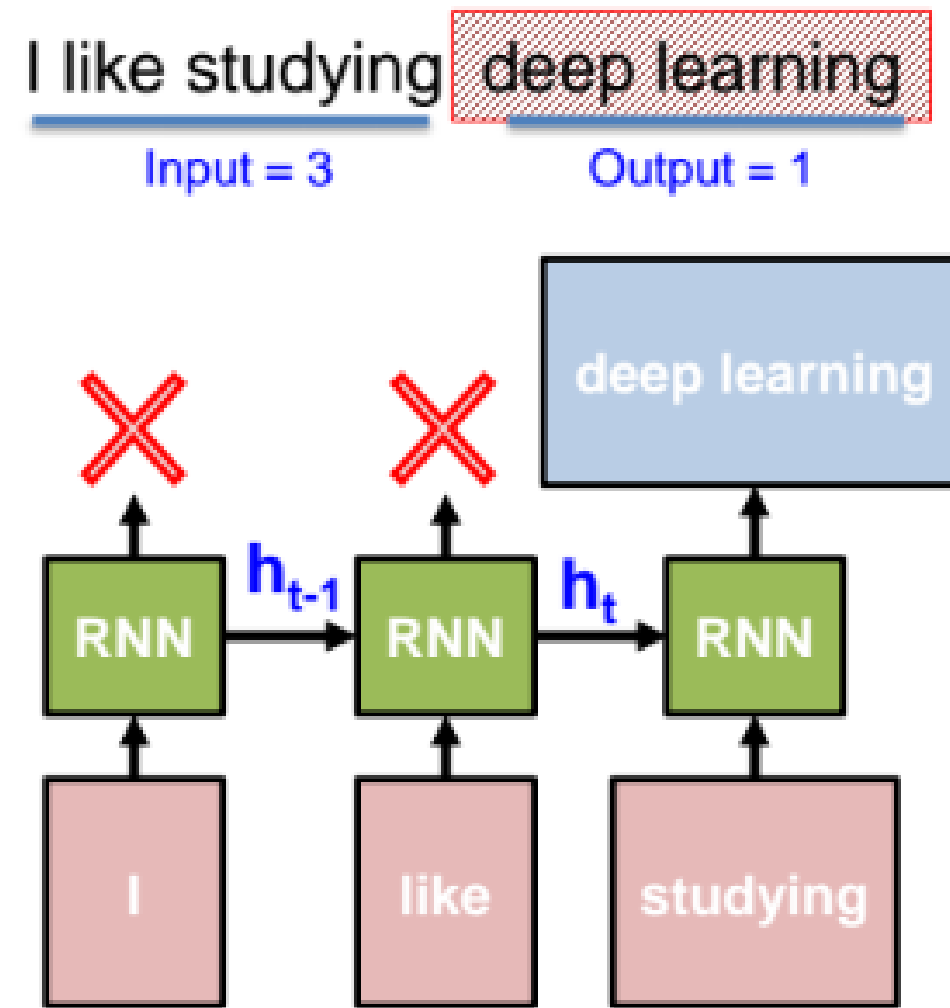
U : 파라미터인 tensor 값 = 가중치 W_{xh}

V : 파라미터인 tensor 값 = 가중치 W_{hy}

W : 파라미터인 tensor 값 = 가중치 W_{hh}

RNN

RNN 적용 예시



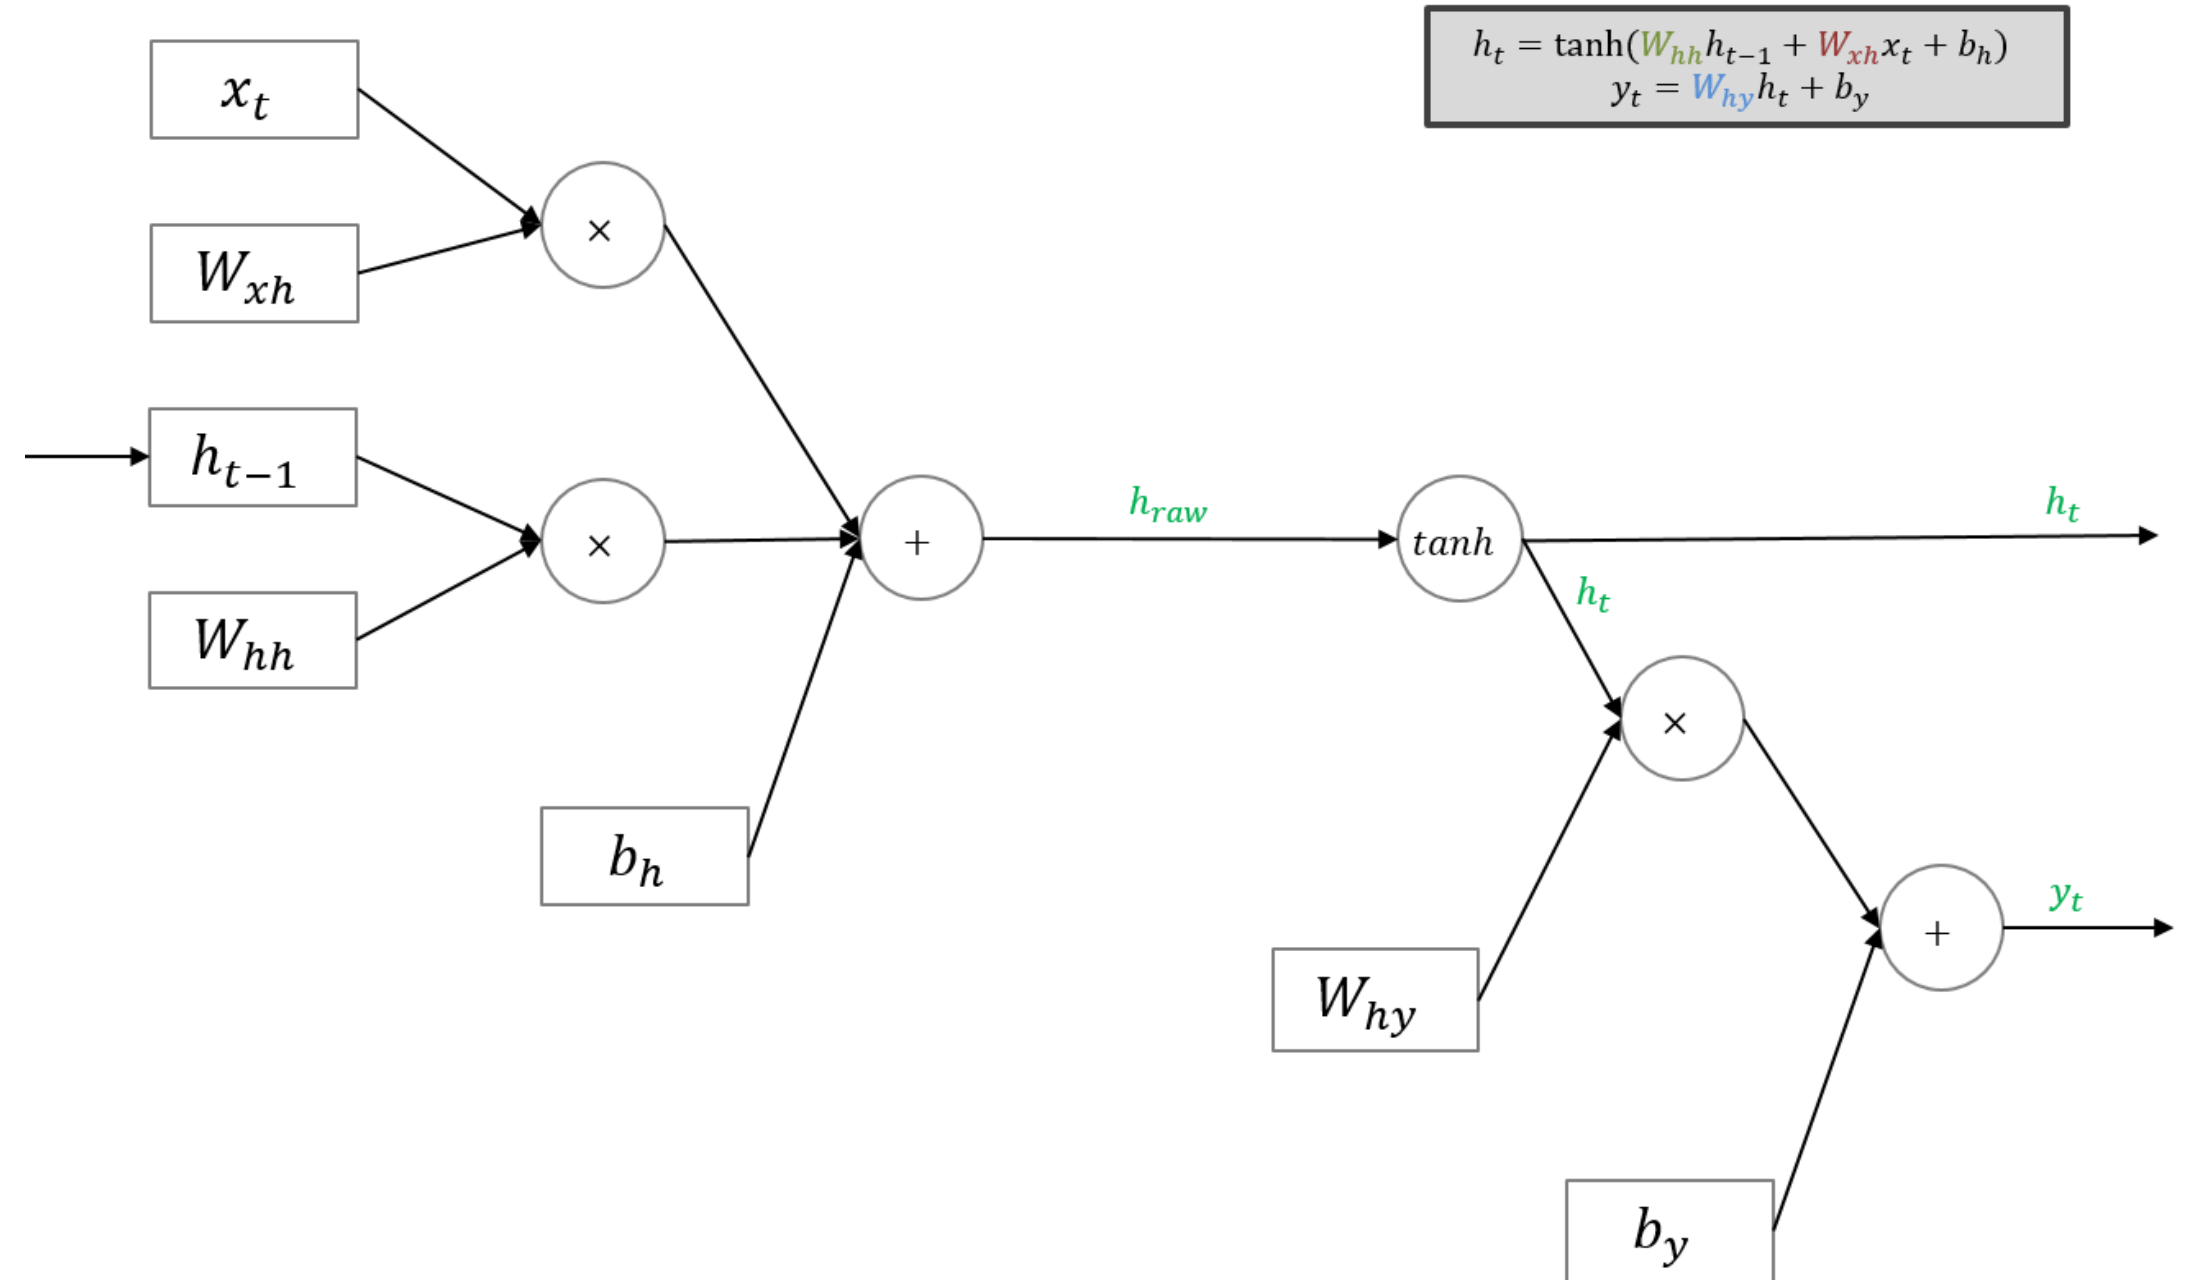
POS TAGGING

RNN

RNN의 Forward Propagation

특징 :


- CAN'T BE PARALLELIZED
- loss function은 전체 합치기



RNN

RNN의 Backward Propagation

- 이러한 과정을 BPTT라고 함



RNN


RNN의 한계점

- Gradient Vanishing / Exploding
 - 파라미터가 공유되기 때문에
 - (1) parameter가 1보다 크면 : gradient가 무한대로 가서 gradient exploding
 - (2) parameter가 1보다 작으면 : gradient가 0으로 가서 gradient vanishing

LSTM

LSTM 이란

- Long-short term memory
- 메모리를 여러 개로 나눔
- 컨베이어 벨트처럼 행동하며 state를 잘 유지해서 전파가 잘 되도록 함



<LSTM>

LSTM

LSTM Cell

- (개념 설명)

forget gate $f_t = \sigma(W_f x_t + V_f h_{t-1} + b_f)$


input gate $i_t = \sigma(W_i x_t + V_i h_{t-1} + b_i)$

$$\tilde{C}_t = \tanh(W_g x_t + V_g h_{t-1} + b_g)$$

hidden output $C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t$

gate $o_t = \sigma(W_o x_t + V_o h_{t-1} + b_o)$


output $h_t = o_t \odot \tanh(C_t)$



LSTM

LSTM Cell – Forget Gate

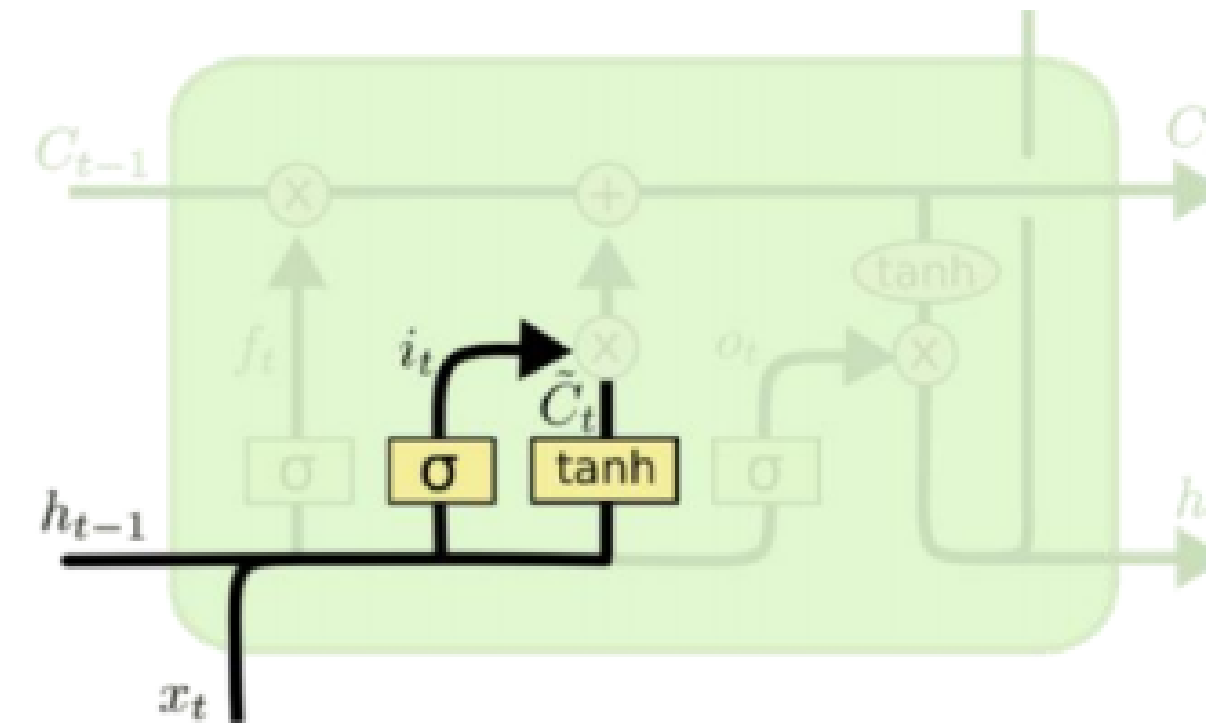
- 과거의 정보를 얻기 위한 게이트
- h_{t-1} 와 x_t 에 대해 sigmoid를 씌워준 값.
- Output 종류
 - 0 : forget
 - 1 : preserve (유지)



LSTM

LSTM Cell – Input Gate


- 현재의 정보를 기억하려는 게이트
- h_{t-1} 와 x_t 에 대해 sigmoid와 tanh를 씌워준 값으로 hadamard 곱을 함



LSTM

LSTM Cell – Update Gate

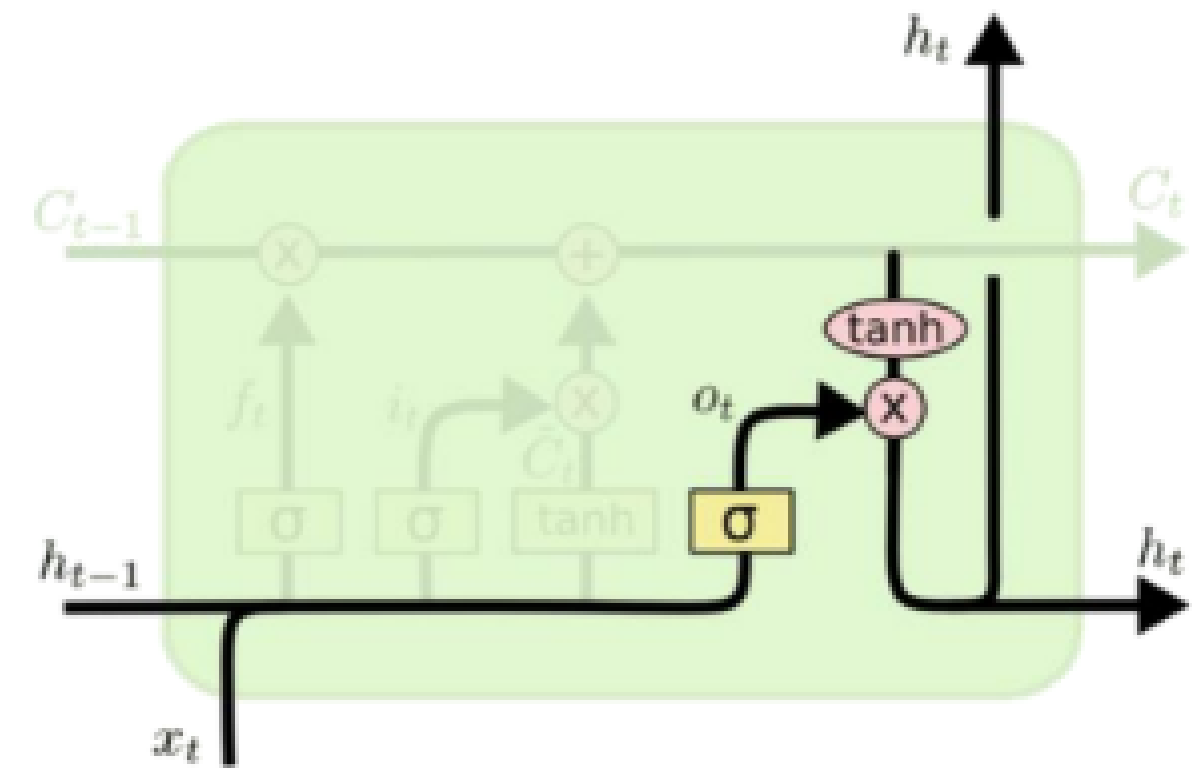
- 얼마나 업데이트를 할 건지 결정하는 게이트
- forget gate와 input 게이트를 hadamard 연산을 통해 계산함



LSTM

LSTM Cell – Output Gate

- 무엇을 결과물로 내보낼지를 결정함



LSTM

LSTM이 Vanishing Gradient을 해결한 방식

- f 가 sigmoid의 output이 되므로 explode는 완전히 해결함
- f 가 sigmoid의 output이 되므로 1에 가까울수록 vanishing이 최소화됨
- 완벽하게 Vanishing Gradient를 해결하진 않았지만, 더 오래 기억할 수 있도록 함

과제

인터넷에 있는
CNN, RNN, LSTM 코드
찾아보고 돌려보기

NEKA

THANK YOU